Relatório de Engenharia e Análise de Dados

Grupo 2 — Educação: Ensino Superior | Censo 2024 (INEP) com Integração Web (read_html & API)

EQUIPE / INTEGRANTES DO GRUPO 2

Gustavo Henrique Tavares Borges
Matrícula: 2311157

João Pedro Barbosa Moreira
Matrícula: 2312662

Igor Augusto Ribeiro de Paula Martins
Matrícula: 2312171

Ygor Gomes Rocha
Matrícula: 2312663

Elton Dourado De Azevedo Filho
Matrícula: 2310514

FONTE PRIMÁRIA	FONTES WEB / API	TOTAL NACIONAL	DATASETS GERADOS
INEP / MEC (Sinopse 2024)	Wikipédia (Censo IBGE) & API IBGE	2.561 IES Ativas (2024)	sinopse_limpa.csv / web_indicators.csv

1. Contexto e Objetivos do Estudo

A **Sinopse Estatística da Educação Superior** é o principal instrumento oficial de divulgação consolidada do Censo da Educação Superior no Brasil. Trata-se de uma planilha concebida originariamente para *leitura humana visual*, caracterizada por títulos no topo, notas metodológicas no rodapé, cabeçalhos em múltiplos níveis com células mescladas na horizontal e vertical, além de linhas de total intercaladas com linhas de estados e municípios na mesma coluna.

O objetivo fundamental deste trabalho é aplicar as técnicas de **Engenharia de Dados (Data Wrangling)** para transformar a estrutura humana da planilha em um conjunto de dados perfeitamente tabular (padrão *Tidy Data*), habilitando operações analíticas consistentes e enriquecendo a análise com **coleta web via `pandas.read_html()`** e **consumo de API pública oficial**.

2. Descrição das Fontes de Dados e Confiabilidade

- **Fonte Primária — INEP / MEC:** Censo da Educação Superior 2024. Coleta anual obrigatória por lei para todas as Instituições de Ensino Superior (IES) públicas e privadas do Brasil. Homologada pelo MEC. Fornece dados altamente confiáveis, com limitações restritas à sua natureza agregada (sem microdados individuais de estudantes nesta tabela).
- **Fonte Web Secundária — Wikipédia (read_html):** Dados demográficos do Censo Demográfico do IBGE transcritos na Wikipédia. Embora a Wikipédia seja colaborativa, os dados extraídos replicam os totais oficiais homologados do Censo IBGE. Foi tratada a proteção HTTP 403 com cabeçalho `User-Agent`.
- **Fonte API Governamental — API de Localidades do IBGE:** Endpoint REST oficial (`servicodados.ibge.gov.br`) mantido pelo IBGE, retornando metadados cadastrais imutáveis (códigos IBGE, siglas oficiais e macrorregiões).

3. Tabela Comparativa de Auditoria: Antes x Depois

Métrica de Auditoria	Antes (Leitura Padrão)	Depois (Dataset Limpo)	Técnica de Tratamento Aplicada
Formato (Linhas x Colunas)	746 x 37	731 x 40	Remoção de títulos e rodapés; expansão de colunas dimensionais (`nivel`, `local`, `categoria`).
Colunas sem nome ('Unnamed')	36 de 37 (97%)	0 (0%)	Reconstrução da árvore de rótulos por concatenação hierárquica (`Pai | Filho | Subnível`).
Células vazias no cabeçalho	97 de 148 (66%)	0 (0%)	Preenchimento progressivo horizontal (`ffill`) condicionado à integridade do nó pai superior.
Linhas que não são dados	15 linhas	0 linhas	Mapeamento por densidade de valores numéricos para isolar exatamente o bloco de dados (linhas 10 a 740).
Colunas de valores como texto	34 de 36 colunas	0 colunas	Coerção numérica com Pandas (`pd.to_numeric`) e conversão para o tipo seguro `Int64`.
Símbolos no lugar de números	1.423 células	0 células	Substituição de traços estatísticos `"-"` (convenção do INEP para frequência zero) pelo numeral `0`.
Primeira coluna (Estrutura)	Geografia e totais misturados	Estrutura atômica em 3 níveis	Desagregação condicional em `nivel` (Brasil, Região, UF, Município), `local` e `categoria`.

4. Detalhamento e Explicação de Cada Comparação

- **Formato da Matriz (746x37 para 731x40):** Eliminação de 15 linhas espúrias (títulos institucionais, linhas em branco e notas técnicas do INEP) e criação de 3 colunas dimensionais para permitir filtragem analítica imediata.
- **Colunas 'Unnamed' (de 36 para 0):** Ao ler células mescladas sem tratamento, o Pandas preenche colunas sem texto na primeira linha com `Unnamed`. A função `achatar_cabecalho()` recompôs os 4 níveis originais preservando toda a semântica institucional.
- **Propagação Segura sem Vazamento:** A propagação horizontal com `ffill()` foi agrupada pelos ancestrais superiores, impedindo que o rótulo "Pública" invadisse indevidamente o bloco de colunas "Privada".
- **Normalização de Símbolos Numéricos (1.423 traços):** O traço estatístico `"-"` impedia a execução de somas e médias. Sua conversão para zero e tipagem com `Int64` garantiu integridade analítica total.

5. Validação Matemática da Limpeza

- **Total Brasil oficial no INEP:** 2.561 instituições de ensino superior.
- **Soma das 27 UFs:** 2.561 instituições (**Convergência de 100%**).
- **Soma das 5 Regiões:** 2.561 instituições (**Convergência de 100%**).
- **Conformidade das colunas:** 33 de 33 colunas numéricas com validação perfeita.

> **Alerta Metodológico: Risco da Análise sem Limpeza**
> Uma soma direta na primeira coluna antes da desagregação geraria **10.244 instituições** — exatamente **4,0 vezes o valor real** do país, devido à sobreposição de totais municipais, estaduais, regionais e nacionais.

6. Destaque: Leitura de Dados da Web (read_html) e Consumo de API

Para enriquecer o estudo e atender com excelência aos critérios de coleta web, integramos dados populacionais e cadastrais ao total de IES de cada estado:

- **Tratamento do Erro HTTP 403:** A Wikipédia bloqueia requisições automatizadas sem cabeçalho identificador. O problema foi superado injetando `headers={"User-Agent": "Mozilla/5.0"}` na requisição antes de passar o HTML para `pandas.read_html()`.
- **Consumo de API REST:** A API oficial de Localidades do IBGE foi consumida em tempo de execução para padronização de siglas (UF) e códigos geográficos.
- **Nova Métrica Per Capita:** Cruzando o total de IES com a população de cada UF, calculamos o indicador de **IES por 1 milhão de habitantes**:

Sigla	Estado (UF)	Região	Total de IES (INEP)	População (Censo IBGE / Wiki)	IES por 1 Milhão de Habitantes
DF	Distrito Federal	Centro-Oeste	63	3.009.996	**20,93** (1º no Brasil)
MT	Mato Grosso	Centro-Oeste	74	3.950.330	**18,73** (2º no Brasil)
AP	Amapá	Norte	15	809.953	**18,52** (3º no Brasil)
RO	Rondônia	Norte	31	1.757.338	**17,64** (4º no Brasil)
GO	Goiás	Centro-Oeste	128	7.495.033	**17,08** (5º no Brasil)
ES	Espírito Santo	Sudeste	67	4.150.692	**16,14**
TO	Tocantins	Norte	23	1.595.994	**14,41**
PR	Paraná	Sul	171	11.952.456	**14,31**
PI	Piauí	Nordeste	48	3.392.617	**14,15**
MG	Minas Gerais	Sudeste	303	21.460.311	**14,12**

2.561
TOTAL DE IES NO BRASIL
Rede de ensino superior ativa em 2024.

87,6%
REDE PRIVADA
2.244 particulares vs. 317 públicas (12,4%).

20,93
MAIOR DENSIDADE (DF)
IES por milhão de habitantes no topo per capita.

7. Descobertas e Insights do Censo 2024

- **São Paulo lidera em números absolutos:** Concentra 580 IES (22,6% do país). Juntamente com MG, PR, BA e GO, os 5 primeiros estados somam 51,8% do total nacional.
- **Inversão no ranking per capita:** Embora SP seja o maior em volume absoluto (12,56 IES/milhão hab), o **Centro-Oeste (DF, MT, GO)** e estados do Norte lideram na oferta de IES por habitante.
- **Predomínio de Faculdades:** 1.897 Faculdades (74,1%), contra 417 Centros Universitários (16,3%) e 206 Universidades (8,0%).

8. Dificuldades Encontradas e Soluções

1. **Tamanho dos arquivos:** O arquivo original ultrapassa 397 MB zip e 700 MB descompactado. Implementou-se leitura seletiva exclusivamente da aba `1.1`.
2. **Mesclagens verticais no Pandas:** O MultiIndex nativo não preenche mesclagens verticais; exigiu algoritmo próprio de árvore de pais.
3. **Bloqueio 403 em Web Scraping:** Superado com `headers={"User-Agent": "Mozilla/5.0"}` na requisição à Wikipédia.